

IA generativa para aprender y enseñar mejor

Sistemas modernos, arquitectura, evidencia causal y agenda de evaluación

Corte de evidencia: 10 de agosto de 2026

Tesis central. La unidad relevante no es el modelo de lenguaje, sino el sistema pedagógico completo: currículo verificable, modelo del estudiante, política de tutoría, herramientas, límites, conducción humana y medición independiente.

+0.125 DE

efecto medio

14 RCT; 191 estimaciones

0.12 DE

tutoría/instrucción IA

promedio metaanalítico

No probado

GenAI > adaptativo clásico

diferencia imprecisa

La conclusión en una frase

Los mejores resultados aparecen cuando la IA está encajada dentro de una secuencia didáctica estructurada, exige esfuerzo cognitivo, usa contenido comprobado, entrega información accionable al docente y se evalúa con pruebas sin asistencia; el “chat inteligente” genérico no ofrece esas garantías.

Alcance Educación escolar y superior; tutores conversacionales, sistemas adaptativos, copilotos para docentes/tutores, plataformas multimodales y despliegues de baja conectividad. Se distingue sistemáticamente entre capacidades declaradas, telemetría de producto y evidencia causal de aprendizaje.

INFORME COMPLETO

SECCIÓN

Resumen ejecutivo

Una lectura sintética de lo que existe, cómo funciona y qué demuestra la evidencia causal.

1

Respuesta directa. Sí existen sistemas modernos capaces de sostener diálogo, adaptar explicaciones, diagnosticar errores, seleccionar ejercicios, recuperar prerrequisitos, usar voz/imagen y apoyar al docente. Pero esas capacidades no vienen automáticamente de un LLM. Las implementaciones más sólidas construyen una arquitectura alrededor del modelo y limitan deliberadamente su libertad.

El objeto de análisis es el sistema, no el chatbot — Un tutor eficaz combina currículo, learner model, política pedagógica, generación, herramientas, guardrails, orquestación humana y medición.

2

El campo avanza de chat genérico a tutor orquestado — Khanmigo, Guided Learning, Study Mode y Claude Learning Mode añaden conductas de tutoría; los sistemas adaptativos clásicos añaden la disciplina de la secuenciación y del seguimiento de dominio.

3

La evidencia media es favorable y moderada — El metaanálisis de Burneo et al. (2026) reúne 191 tamaños de efecto de 14 RCT en diez economías y estima +0.125 desviaciones estándar frente a instrucción tradicional; el subconjunto de tutoría/instrucción IA promedia +0.12 DE [1].

4

No está demostrado que GenAI supere al adaptativo pre-LLM — La diferencia estimada entre generaciones es pequeña e imprecisa. Mindspark, ASSISTments, ALEKS/MATHia y otros recordatorios obligan a no confundir naturalidad conversacional con eficacia pedagógica.

5

El gran riesgo es optimizar la respuesta asistida — Bastani et al. muestran que GPT irrestricto mejora fuertemente la práctica pero reduce 17% el examen posterior sin IA; un tutor con guardrails elimina el daño, aunque no supera al control en el examen autónomo [3].

6

Los casos más positivos son paquetes de diseño e implementación — Harvard, Nigeria y Sierra Leona combinan contenido predefinido, sesiones pautadas, docentes/facilitadores, trabajo en pares o secuencias controladas. Sus efectos no identifican “el LLM solo”.

7

El humano no desaparece: cambia de función — Tutor CoPilot elevó dominio en 4 pp, y 9 pp con tutores inicialmente menos valorados, sugiriendo que la IA puede escalar expertise en vez de sustituir la relación tutorial [6].

8	Acceso no es exposición — En dos RCT de lectura, cerca de la mitad de los alumnos nunca usó la plataforma y el uso medio fue de minutos por semana; el apoyo humano aumentó el engagement, pero no alcanzó la dosis requerida ni produjo gains [8].
9	La personalización genuina debe ser verificable — Debe poder mostrarse qué estima el sistema, qué evidencia usa, por qué escogió la próxima acción y cómo cambia su estrategia. Cambiar tono o recordar el chat es personalización superficial.
10	La evaluación correcta es longitudinal y sin ayuda — Prueba independiente, retención, transferencia, tiempo a dominio, autonomía, metacognición, equidad, carga docente, costos y adopción deben analizarse juntos.

Juicio final

La evidencia ya justifica pasar de demostraciones a pilotos rigurosos y, en algunos contextos, a despliegues controlados. Todavía no justifica tratar a un tutor generativo autónomo como sustituto general del docente ni asumir que su efecto será positivo sin currículo, guardrails, dosificación y evaluación independiente.

INFORME COMPLETO
SECCIÓN

1. Alcance, método y definiciones

Qué se incluye, qué se excluye y cómo se distingue una capacidad de una evidencia de aprendizaje.

1.1 Pregunta de investigación

Este informe pregunta qué sistemas contemporáneos usan IA —en especial IA generativa— para hacer el aprendizaje y la enseñanza más interactivos, adaptativos y personalizados; cómo están contruidos; qué funciones realizan; dónde se despliegan; y qué se ha medido rigurosamente.

El universo incluye educación K-12 y superior, tutoría directa al estudiante, software adaptativo, copilotos para docentes y tutores, apoyo multimodal y despliegues de baja conectividad. No se considera “sistema de aprendizaje” a cualquier chatbot usado ocasionalmente para contestar preguntas: se exige al menos una intención pedagógica explícita, integración curricular, seguimiento del alumno o función docente definida.

1.2 Tres tipos de afirmación que no deben mezclarse

Nivel de evidencia	Pregunta correcta
Capacidad técnica	El sistema puede generar explicaciones, reconocer una imagen, hablar, producir preguntas o acceder a materiales.
Calidad de interacción	Expertos prefieren sus mensajes, comete pocos errores, hace preguntas socráticas o mantiene al alumno activo.
Efecto de aprendizaje	El alumno mejora posteriormente, sin asistencia, en una medida independiente; idealmente retiene y transfiere.

Una gran parte del marketing y de la investigación temprana prueba el primer o segundo nivel y habla como si hubiera demostrado el tercero.

1.3 Jerarquía utilizada en el informe

Grado	Qué permite concluir
A	RCT preregistrado o cuasiexperimento fuerte; outcome independiente y sin asistencia; duración suficiente o seguimiento.

Grado	Qué permite concluir
B	RCT corto, transferencia inmediata, resultado de plataforma o intervención compuesta; causal, pero alcance estrecho.
C	A/B de producto, auditoría de mensajes, benchmark de modelo, preferencia experta o estudio observacional con logs.
D	Encuesta, engagement, caso institucional, testimonio o descripción de producto.

1.4 Limitaciones de la base disponible

- La literatura generativa es muy reciente; algunos resultados proceden de preprints o equipos vinculados al proveedor. Los modelos, interfaces y prompts cambian más rápido que los ciclos de publicación.
- Muchos estudios comparan paquetes completos: IA más tiempo adicional, dispositivos, capacitación, facilitadores o currículo especial. El efecto causal del paquete es válido; el efecto aislado del modelo no está identificado.
- Las medidas suelen ser inmediatas y estrechas. Hay pocos seguimientos demorados, evaluaciones de transferencia lejana, costos comparables, resultados de docentes o despliegues públicos a escala.
- El metaanálisis 2026 no contiene estudios en países clasificados como de bajos ingresos y solo dos reportan costos comparables [1]. El RCT de Sierra Leona apareció después de varias búsquedas de la revisión o bajo criterios distintos, por lo que ilustra la velocidad con que cambia el campo.

INFORME COMPLETO

SECCIÓN

2. De los tutores inteligentes a los sistemas generativos

La novedad no reemplaza la tradición: cambia la interfaz y amplía el espacio de acciones, pero hereda el problema de decidir qué enseñar después.

2.1 La arquitectura clásica

Los sistemas tutores inteligentes (ITS) se concibieron con cuatro componentes: un modelo del dominio, un modelo del estudiante, un módulo pedagógico y una interfaz. El dominio representa qué conocimientos y procedimientos existen; el learner model infiere qué domina cada alumno; el módulo pedagógico decide la intervención; la interfaz entrega el ejercicio y feedback.

Knowledge Tracing formalizó una idea clave: el conocimiento es latente y se actualiza probabilísticamente a partir de respuestas [22]. Las variantes modernas incluyen modelos bayesianos, teoría de respuesta al ítem, Deep Knowledge Tracing y modelos que combinan secuencia, dificultad, tiempo, pistas y olvido [23].

Sistemas como ALEKS representan conjuntos factibles de conocimientos y seleccionan temas “ready to learn” [18]. MATHia rastrea habilidades paso a paso y ofrece feedback contextual [19]. ASSISTments combina práctica, feedback inmediato y reportes que permiten al docente intervenir [11,26]. Mindspark diagnostica el nivel real y ajusta contenido, incluso cuando existe una gran brecha entre grado nominal y competencia [10].

2.2 Qué cambia con los LLM

Cambio	Implicación pedagógica
Lenguaje abierto	El alumno puede explicar su razonamiento, pedir otra representación, negociar el ritmo y formular preguntas no previstas.
Generación bajo demanda	Ejemplos, analogías, cuestionarios, casos, role-play, código, simulaciones y retroalimentación pueden producirse en tiempo real.
Multimodalidad	Texto, voz, imagen, diagramas y pantalla permiten tutorar tareas que antes exigían interfaces especializadas.
Generalidad	Un mismo modelo cubre muchas materias e idiomas; baja el costo de autoría inicial, pero aumenta el riesgo de errores y desalineación curricular.

Cambio	Implicación pedagógica
Capacidad de herramienta	El modelo puede consultar fuentes, usar calculadoras/solvers, ejecutar código y coordinar agentes especializados.
Interfaz social	La conversación aumenta naturalidad y percepción de apoyo; también puede inducir confianza excesiva y ocultar un learner model débil.

2.3 Lo que no cambia

- Sigue siendo necesario decidir qué concepto enseñar, qué dificultad usar, qué evidencia cuenta como dominio, cuándo interrumpir, cuánto ayudar y cuándo volver sobre un prerrequisito.
- Un modelo lingüístico no observa directamente el conocimiento. Puede inferirlo de una conversación, pero esa inferencia es sensible al prompt, al estilo verbal, a la motivación y a la calidad de las tareas. La memoria narrativa no reemplaza un estado estructurado y calibrado.
- La pedagogía tiene objetivos que compiten con la satisfacción inmediata. El usuario suele preferir una respuesta rápida; el aprendizaje exige esfuerzo, recuperación, error, espera y retirada de apoyo. Por ello, el sistema no debe optimizar solo aprobación, fluidez o resolución.

Síntesis histórica. La IA generativa resuelve gran parte del problema de interfaz y autoría. No resuelve automáticamente el problema central de la tutoría inteligente: estimar el estado cognitivo y escoger la intervención que maximiza aprendizaje futuro, no éxito inmediato.

INFORME COMPLETO

SECCIÓN

3. Anatomía de un sistema moderno

Ocho capas que permiten distinguir una aplicación pedagógica de un chatbot con apariencia educativa.

3.1 Vista de conjunto

Capa	Nombre	Función
8	Medición y aprendizaje del sistema	Outcomes, experimentos, auditoría, costos, equidad, logs y actualización de políticas.
7	Orquestación humana e institucional	Docente/tutor, LMS, asignaciones, panel, límites, escalamiento y soporte.
6	Seguridad y guardrails pedagógicos	Integridad, privacidad, answer withholding, esfuerzo, incertidumbre, contenido sensible.
5	Generación e interfaz multimodal	Diálogo, voz, imagen, simulación, role-play, explicaciones y feedback.
4	Grounding, contenido y herramientas	RAG, materiales, banco de ítems, worked solutions, calculadora, solver, código y verificadores.
3	Política pedagógica / planner	Próxima acción, secuencia, dificultad, pistas, repaso, fading y escalamiento.
2	Modelo del estudiante	Mastery, errores, historial, confianza, ritmo, objetivos, afecto y contexto.
1	Modelo del dominio y currículo	Conceptos, competencias, prerrequisitos, estándares, tareas y criterios de calidad.

Flujo mínimo de una intervención

Observar → inferir → decidir → generar/verificar → intervenir → medir. El sistema capta la respuesta y el contexto; actualiza el learner model; el planner elige una acción; el generador produce una realización; herramientas verifican; el alumno responde; y el resultado alimenta el estado y la evaluación.

3.2 Capa 1: modelo del dominio

El dominio es la representación de lo que se pretende aprender. Puede ser una jerarquía curricular, un grafo de conocimientos, una matriz de estándares, una red de prerrequisitos, un conjunto de procedimientos o una biblioteca de casos. Debe vincular cada competencia con tareas, respuestas, errores frecuentes, explicaciones y criterios de dominio.

La generación libre sin un dominio explícito produce cobertura irregular: el modelo puede saltar pasos, introducir conceptos prematuros o confundir variantes curriculares. Los mejores sistemas restringen el espacio: Khanmigo conoce el ejercicio de Khan Academy; Eedi parte de diagnósticos de misconception; el tutor de Kestin recibió materiales y soluciones detalladas; GPT Tutor incorporó la solución y errores comunes en el prompt [2,3,7,13].

Para materias con respuestas verificables, el dominio debe contener worked solutions y validadores. Para escritura, ciencias sociales o debate, requiere rúbricas, corpus autorizado, ejemplos ancla y criterios de calidad; no basta con “estar de acuerdo” con el alumno.

3.3 Capa 2: modelo del estudiante

El learner model puede operar en varias escalas simultáneas:

Escala	Estado útil
Turno	Qué intenta hacer ahora; error actual; pasos visibles; solicitud explícita.
Sesión	Conceptos trabajados, pistas usadas, tiempo, persistencia, dependencia y estrategia.
Curso	Mastery por habilidad, prerrequisitos, olvido, transferencia, objetivos y calendario.
Persona/contexto	Idioma, accesibilidad, experiencia, motivación y restricciones; usar con prudencia para evitar estereotipos.

Un historial textual extenso es información, no necesariamente un modelo. Para ser accionable, debe resumirse en variables pedagógicas: probabilidad de dominio, misconception, confianza de la inferencia, evidencia reciente, uso de pistas y próximo prerrequisito.

Khan Academy encontró que un resumen estructurado de intentos recientes elevó 3.4% la corrección del siguiente ítem y que revelar prerrequisitos no dominados más una revisión breve añadió 2.7%; pasar más datos sin estructura no siempre produjo mejoras [13]. Es una demostración de ingeniería importante: más contexto no equivale a mejor personalización.

El modelo debe admitir incertidumbre y revisión. Una inferencia errónea puede encerrar al estudiante en contenido demasiado fácil, atribuir una equivocación conceptual a descuido o adaptar el tono en vez de resolver el déficit.

3.4 Capa 3: política pedagógica

Acción	Ejemplos de política
Diagnosticar	Pedir explicación, seleccionar una pregunta discriminante, contrastar dos respuestas o revisar un prerrequisito.
Andamiar	Pista conceptual → pista estratégica → paso parcial → worked example; evitar saltar directamente al resultado.
Secuenciar	Elegir dificultad y concepto siguiente, intercalar temas, espaciar recuperación y ajustar ritmo.
Regular ayuda	Exigir intento, limitar pistas, detectar dependencia y retirar gradualmente el soporte.

Acción	Ejemplos de política
Promover metacognición	Solicitar predicción, confianza, explicación del error, comparación de métodos y plan de estudio.
Escalar	Derivar al docente/tutor ante riesgo, bloqueo persistente, ambigüedad curricular o baja confianza del sistema.

La política puede implementarse mediante reglas, máquinas de estado, secuencias diseñadas, bandits, reinforcement learning o un LLM controlador. La opción más confiable en 2026 es híbrida: estructura externa para decisiones de alto impacto y generación flexible para realizar la intervención.

Kestin et al. informan que el prompt no controlaba de manera suficientemente fiable una secuencia multipartes, por lo que la plataforma impuso externamente el orden [2]. Este detalle es central: la conducta pedagógica crítica no debe depender de que el modelo “recuerde” siempre la instrucción.

Una política óptima no es la que maximiza exactitud del siguiente paso con asistencia; puede preferir una dificultad que produzca error informativo o requerir recuperación. El objetivo debe ser desempeño futuro, autonomía y retención.

3.5 Capa 4: grounding, herramientas y verificación

Componente	Contribución
RAG curricular	Recupera fragmentos de syllabus, textos, notas, estándares o recursos autorizados; reduce deriva y permite citas.
Banco de ítems	Proporciona tareas calibradas, distractores vinculados a misconceptions y resultados comparables.
Calculadora/solver	Separa razonamiento lingüístico de cálculo; verifica equivalencias, unidades y pasos.
Ejecución de código	Prueba programas, genera tests, visualiza y comprueba resultados; requiere sandbox y límites.
Verificador factual	Contrasta afirmaciones con fuentes; marca incertidumbre y bloquea contenido no sustentado.
Agentes especializados	Router decide si invocar matemática, escritura, búsqueda, pronunciación o seguridad.

Khanmigo emplea un agente matemático especializado para verificar cálculos y expresiones; sus experimentos muestran que routing, concisión y pre-checks reducen latencia sin perder exactitud [13]. La lección general es que el tutor no debe pedirle al mismo modelo que comprenda, calcule, juzgue y enseñe sin instrumentos independientes.

3.6 Capa 5: interfaz generativa y multimodal

La interfaz permite conversaciones de explicación, role-play, feedback de escritura, práctica oral, interpretación de diagramas, generación de ejemplos y simulación. El valor distintivo de GenAI es la elasticidad: puede cambiar representación y responder a preguntas inesperadas a un costo marginal bajo.

La multimodalidad puede ampliar acceso —voz, lectura en voz alta, descripción visual, traducción— y permitir feedback sobre pronunciación, manuscritos o experimentos. Sin embargo, la facilidad de producir material no asegura calidad, progresión ni compatibilidad con el currículo.

La personalidad, empatía simulada y continuidad pueden apoyar persistencia, pero no deben confundirse con diagnóstico psicológico. En menores, las decisiones sobre antropomorfismo, vínculo, persuasión y límites requieren especial gobernanza.

3.7 Capa 6: guardrails de aprendizaje y seguridad

Tipo	Mecanismos
Productivos	Intento antes de pista; pista gradual; no entregar respuesta; explicación propia; fading; pausa antes de reveal.
Epistémicos	Citas, solución verificada, estimación de confianza, abstención, detección de contradicción y versionado.
Integridad	Límites por tarea/curso; modos de práctica vs evaluación; trazabilidad y diseño de assessments auténticos.

Tipo	Mecanismos
Protección	Privacidad, menores, contenido sensible, sesgo, accesibilidad, prevención de manipulación y escalamiento humano.

Bastani et al. proporcionan el contraste más limpio: el sistema irrestricto facilitó una “muleta”; el tutor con solución incorporada e instrucciones de dar pistas mitigó el daño [3]. Guardrails no son censura periférica: son parte de la función de producción de aprendizaje.

3.8 Capas 7 y 8: orquestación y medición

La orquestación define quién fija objetivos, cuándo se usa la IA, qué ve el docente, cómo se forman grupos, qué incidentes escalan y cómo se integra al LMS. En Sierra Leona, los docentes diseñaron objetivos, facilitaron pares y consolidaron la clase; en Nigeria, el programa fue after-school, con profesores y guía de prompting [4,5].

Los paneles útiles no solo cuentan mensajes. Deben mostrar dominio, misconceptions, uso de pistas, dependencia, temas no cubiertos, alumnos sin uso, evidencia que sustenta la inferencia y acciones sugeridas. El docente debe poder corregir el estado o bloquear recomendaciones.

La medición debe alimentar tanto la evaluación causal como la mejora del producto. OpenAI propone combinar instrucciones de sistema, clasificadores de interacciones, graders de calidad, seguimiento longitudinal y medidas cognitivas/metacognitivas [14]. La arquitectura es plausible; su validez depende de calibrarla contra outcomes humanos e independientes.

INFORME COMPLETO

SECCIÓN

4. Qué hacen pedagógicamente

Una taxonomía operacional de las conductas que un sistema puede ejecutar y de la evidencia que debería demostrar.

Conducta	Implementación	Promesa y riesgo	Métrica adecuada
Tutoría socrática	Pregunta antes de explicar; solicita evidencia; confronta contradicciones.	Puede activar razonamiento; puede convertirse en interrogatorio ritual o preguntas obvias.	Calidad de pregunta + desempeño posterior.
Pistas graduadas	Hint ladder desde concepto a paso parcial; reveal tardío.	Preserva esfuerzo; requiere diseño por dominio.	Uso de pistas, éxito sin pista siguiente, retención.
Worked examples	Ejemplo completo o parcialmente resuelto; comparación de soluciones.	Muy eficaz para novatos; debe alternar con práctica y fading.	Transferencia a problemas isomorfos/nuevos.
Feedback inmediato	Señala error, localiza paso y explica por qué.	Evita consolidar errores; demasiado feedback reduce autorregulación.	Corrección del error y desempeño demorado.
Retrieval practice	Preguntas sin apoyo, quizzes, recuerdo libre.	Mejora retención; la IA debe tolerar silencio y no rescatar pronto.	Retención demorada.
Espaciado e intercalado	Revisita conceptos según olvido; mezcla tipos de problema.	Exige memoria longitudinal y scheduler.	Curva de retención y transferencia.
Diagnóstico de misconception	Distingue error conceptual, procedimental, lectura o descuido.	Permite intervención precisa; inferencias pueden ser frágiles.	Validez diagnóstica contra experto.
Autoexplicación	Pide justificar, predecir, comparar y explicar el error.	Promueve elaboración; respuestas superficiales deben detectarse.	Calidad de explicación + gains.
Mastery learning	Avanza cuando se alcanza criterio; reenseña prerrequisitos.	Adecuado para heterogeneidad; riesgo de encierro o baja ambición.	Tiempo a dominio + cobertura + outcome común.
Role-play/simulación	Conversación en lengua, paciente, negociación, debate o laboratorio.	Práctica auténtica; evaluación y seguridad más complejas.	Performance humana o rúbrica externa.
Metacognición	Planifica, calibra confianza, monitorea comprensión y decide estrategia.	Clave para autonomía; todavía poco medida.	Calibración, persistencia, transferencia futura.
Apoyo docente	Planifica, diferencia, crea rúbricas, analiza errores, recomienda grupos.	Reduce carga o eleva calidad; también puede automatizar juicio débil.	Tiempo, calidad de materiales y outcome del alumno.

4.1 La distinción entre scaffolding y answer delivery

El sistema debe preservar la parte del problema que constituye el aprendizaje. En matemática, puede explicar el concepto o señalar el paso incorrecto sin completar la operación. En escritura, puede preguntar por la tesis y ofrecer

una estructura sin redactar el argumento evaluado. En programación, puede crear tests, localizar el bug o explicar el stack trace sin reemplazar la implementación completa. La frontera depende del objetivo, del nivel y de si se trata de práctica o evaluación.

4.2 Productive struggle como variable de diseño

La fricción no es un defecto si produce recuperación, generación, comparación o corrección. Un tutor debe decidir qué esfuerzo es productivo y qué bloqueo es ruido. Esto requiere indicadores de tiempo, intentos, patrón de error, confianza y progreso; no una regla fija de “nunca dar respuestas”. La política óptima puede revelar un paso para liberar capacidad cognitiva y conservar el núcleo conceptual.

4.3 Personalización: cuatro niveles

Nivel	Qué cambia	Estado del campo
I. Presentación	Idioma, tono, longitud, vocabulario, formato y accesibilidad.	Común en cualquier LLM; débil evidencia de que por sí sola mejore aprendizaje.
II. Interacción	Ejemplo, pregunta, pista, modalidad y feedback según el turno.	Útil; puede basarse en inferencia local sin memoria de dominio.
III. Decisión pedagógica	Próxima acción y dificultad basadas en mastery, error y esfuerzo.	Requiere learner model + policy; es el núcleo adaptativo.
IV. Trayectoria	Secuencia curricular, prerrequisitos, olvido, objetivos y transferencia entre sesiones.	Difícil; exige persistencia, evaluación y coordinación institucional.

Personalización falsa. Una respuesta que menciona el nombre del alumno, adopta un tono amistoso o reformula el mismo contenido no demuestra adaptación cognitiva. La pregunta auditora es: ¿qué estado cambió, con qué evidencia y qué decisión distinta produjo?

INFORME COMPLETO

SECCIÓN

5. Panorama de sistemas y productos

Qué ofrecen las plataformas más relevantes y dónde termina la evidencia pública.

5.1 Tutores conversacionales de propósito amplio

Sistema	Contexto	Arquitectura visible	Evidencia pública	Lectura
Khanmigo	Estudiante y docente; integrado a ejercicios de Khan Academy.	Problema actual, historial reciente, skill/prerequisite signals, agente matemático, guías de tutoría y paneles.	A/B internos de latencia, engagement y next-item correctness; no equivale a RCT externo de retención.	Alta integración curricular; producto maduro.
ChatGPT Study Mode	Estudio general y universitario; cualquier materia/modelo disponible.	Custom system instructions, preguntas interactivas, scaffolding, checks, archivos y multimodalidad.	RCT temprano >300: microeconomía ≈15% superior; neurociencia positivo no significativo; análisis en curso.	Flexibilidad máxima; learner model longitudinal todavía emergente.
Gemini Guided Learning / LearnLM	Estudio general; despliegues escolares y Classroom.	Modelo ajustado para pedagogía, probing, explicación paso a paso, multimodalidad y grounding.	Sierra Leona +0.258 DE; Eedi exploratorio; benchmarks de preferencia pedagógica.	Mejor evidencia reciente, pero intervenciones compuestas/proveedor asociado.
Claude Learning Mode	Educación superior; Projects e integraciones.	Guía en vez de respuesta, preguntas socráticas, conceptos nucleares, plantillas y contexto del proyecto.	Reportes de uso de estudiantes/docentes; no RCT público comparable.	Buena interfaz de trabajo intelectual; eficacia de aprendizaje no establecida.
Coursera Coach y similares	Aprendizaje dentro de cursos/plataformas.	Chat grounded en materiales del curso, explicación, práctica y traducción.	Encuestas/telemetría predominantemente.	Grounding reduce deriva; evidencia causal limitada.

5.2 Sistemas adaptativos estructurados

Sistema	Núcleo técnico	Dominio	Evidencia/implicación
MATHia	Modelo cognitivo de habilidades; seguimiento paso a paso; feedback y hints contextuales; Skillometer; LiveLab docente.	Matemática escolar.	Tradición ITS y estudios variados; la ventaja es precisión de dominio, no conversación abierta.
ALEKS	Knowledge Space Theory; assessment adaptativo; estado de conocimientos; topics ready-to-learn; reassessment.	Matemática, estadística, química y otros.	Personalización curricular profunda; interfaz menos generativa.
ASSISTments	Problemas curriculares, feedback/pistas, mastery streaks, espaciado y reportes de errores al docente.	Matemática K-12.	RCT 2,850 alumnos: ≈ 0.18 DE; evidencia de que software + uso docente puede funcionar [11].
Mindspark	Diagnóstico del nivel real, contenido adaptativo y ruta individual; puede operar con brechas de grado.	Matemática e idioma.	Lottery RCT: +0.37 DE matemática, +0.23 DE hindi en 4.5 meses [10].

Estos sistemas son el benchmark correcto para GenAI. El metaanálisis 2026 no encuentra una superioridad estadísticamente distinguible de la nueva generación [1]. La oportunidad no es reemplazarlos, sino combinar su learner model, secuenciación y contenido calibrado con la flexibilidad conversacional y multimodal de los LLM.

5.3 Híbridos y copilotos

Sistema/familia	Configuración	Lectura
Eedi/LearnLM	Diagnóstico e ítems de Eedi + chat generativo; mensajes revisados por experto.	La estructura fija el objetivo; el LLM realiza tutoría. Buen modelo de “constrained AI”.
Duolingo	Birdbrain/ruta adaptativa + Roleplay y Explain My Answer generativos.	Generación dentro de una secuencia y un dominio; falta aislar causalmente la capa GenAI.
Tutor CoPilot	Modelo de expert reasoning ofrece sugerencias en tiempo real al tutor; este edita o decide.	IA escala expertise sin eliminar al humano; +4 pp de dominio y mayor efecto con tutores débiles [6].
Herramientas docentes	Planificación, diferenciación, rúbricas, feedback, análisis de clase y materiales.	Pueden reducir carga o mejorar calidad; deben medirse tiempo, calidad y downstream learning, no cantidad generada.
SchoolAI/MagicSchool/rooms	Experiencias controladas por docente, agentes/espacios, parámetros y monitoreo.	Orquestación prometedora; evidencia causal pública todavía escasa.

5.4 Baja conectividad y contextos de recursos limitados

- Rori opera por WhatsApp con microlecciones, práctica, pistas y soluciones; el estudio en Ghana reporta ≈ 0.37 DE con dos sesiones de 30 minutos por semana durante ocho meses, además de instrucción regular [9]. La asignación a nivel escolar y el carácter preliminar exigen cautela.
- Nigeria usó Microsoft Copilot/GPT-4 en un programa after-school de seis semanas, con trabajo en pares, docentes y guía. El resultado compuesto fue $\approx +0.31$ DE y el de inglés $\approx +0.24$ DE [4]. La intervención demuestra viabilidad y efecto del paquete en escuelas públicas, no una tutoría autónoma uno-a-uno.
- Sierra Leona desplegó Guided Learning en clases de matemática dirigidas por docentes: 1,763 estudiantes, 12 escuelas, ocho semanas y +0.258 DE [5]. Los logs muestran interacción mayormente orientada a comprensión, pero el beneficio fue mayor para alumnos con línea base alta, una alerta de equidad.
- La interfaz móvil o conversacional reduce requisitos de ancho de banda, pero no elimina dispositivos compartidos, electricidad, datos, capacitación, soporte, lengua local, alineamiento curricular ni calidad de facilitación. La infraestructura y la implementación son parte del tratamiento.

6. Qué demuestra la evidencia

Resultados principales, identificación causal, límites y comparabilidad.

6.1 Síntesis metaanalítica

191 tamaños de efecto 14 RCT, 10 economías	+0.125 DE aprendizaje vs instrucción tradicional	+0.12 DE tutoría/instrucción IA subconjunto de 6 estudios	0.022 DE diferencial GenAI no significativo; EE 0.075
---	---	--	--

Burneo et al. (2026) aplican criterios comunes y robust variance estimation. El promedio de +0.125 DE se ubica por encima de la mediana de intervenciones educativas de campo, pero mezcla medidas estrechas y amplias y presenta heterogeneidad considerable [1].

Los efectos en outcomes socioemocionales/conductuales promedian +0.029 DE, pero se apoyan en pocos estudios y grados de libertad insuficientes. Los outcomes docentes tampoco permiten una conclusión firme.

La comparación GenAI versus tecnología adaptativa previa no revela ventaja sistemática: coeficiente 0.022 DE con error estándar 0.075. Esto no prueba equivalencia; indica que la base aún no puede ordenar generaciones.

El metaanálisis advierte que no hay estudios incluidos en países de bajos ingresos, solo dos ofrecen costos comparables y la mayoría de las intervenciones fue implementada por investigadores, no por gobiernos a escala.

Interpretación correcta. +0.125 DE es una señal relevante de que los sistemas adaptativos/IA pueden producir aprendizaje. No es un efecto esperado para cualquier producto, materia o despliegue, ni prueba que un tutor generativo sea superior a un buen sistema adaptativo o a tutoría humana.
--

6.2 Estudios causales y cuasicausales principales

Estudio	Diseño	Resultado	Lectura causal/límite
Bastani et al. 2025 [3]	≈1,000 estudiantes; matemática secundaria; clases aleatorizadas; práctica con GPT Base, GPT Tutor o texto; examen sin GPT.	Práctica +48% Base y +127% Tutor. Examen autónomo: Base −17%; Tutor sin diferencia clara vs control.	Distingue productividad asistida de aprendizaje. Guardrails reducen daño. Outcome autónomo fuerte; contexto/implementación específicos.
Kestin et al. 2025 [2]	194 universitarios; crossover; dos lecciones de física; IA vs active learning; pre/post inmediato.	Regresión ≈0.63 DE; estimación por techo 0.73–1.3; mediana 49 vs 60 min; más engagement/motivación.	Tutor altamente diseñado, solución conocida y secuencia externa. Dos lecciones, elite university, test inmediato.
Nigeria 2025 [4]	1,328 aprox.; 9 escuelas públicas; 6 semanas; 12 sesiones de 90 min after-school; randomización.	+0.31 DE compuesto; ≈+0.24 DE inglés; efectos en AI/digital skills.	Efecto del paquete: IA + tiempo + docentes + pares + prompts. Pen-and-paper test; valioso contexto LMIC.
Sierra Leona 2026 [5]	1,763; cluster RCT; 48 aulas/12 escuelas; 8 semanas; docente, dos alumnos por dispositivo.	+0.258 DE ITT; estimación de tratamiento por 12 h ≈0.380 DE bajo supuestos.	Pre-registrado, escala escolar. Reporte proveedor; no delayed/far transfer; heterogeneidad favorece baseline alto.
Tutor CoPilot [6]	900 tutores/1,800 alumnos; RCT en tutoría matemática online de escuelas Title I.	+4 pp probabilidad de dominio; +9 pp con tutores de rating bajo; estrategias de más alta calidad.	Evidencia de copilot humano-IA. Outcome de plataforma y costo estimado; no prueba estandarizada amplia.
Eedi/LearnLM [7]	165 alumnos, 5 escuelas UK; tutor humano vs AI supervisada vs pista estática; Bayesian exploratory.	AI ≈humano en corrección; +5.5 pp en problemas de tema posterior; 74.4% mensajes sin editar, ~76% cero/mínimos cambios.	Cada mensaje supervisado; intervalos exploratorios. Prueba de híbrido seguro, no autonomía.
Rori Ghana [9]	≈500–1,000 según versión; 11 escuelas; dos sesiones/semana, 8 meses; asignación escolar.	≈0.36–0.37 DE matemática.	Prometedor y baja conectividad; extra instruction, estudio preliminar y asignación limitada.
Acceso + humano [8]	≈350 alumnos; 2 RCT; tutor de lectura; acceso solo vs apoyo relacional humano.	Uso +1 y +4.4 min/sem; engagement +71–80%; sin gains de lectura.	Identifica el cuello de botella de adopción/dosificación. No prueba ineficacia si casi no hubo uso.
Mindspark [10]	619; lottery RCT; 4.5 meses after-school.	+0.37 DE matemática; +0.23 DE hindi.	Benchmark pre-LLM; diagnóstico y adaptación estructurada; tiempo adicional incluido.

Estudio	Diseño	Resultado	Lectura causal/límite
ASSISTments [11]	2,850 séptimo grado; 43 escuelas; 2 años; cluster RCT.	≈0.18 DE (otras síntesis/producto reportan 0.22 según especificación).	Software + PD + uso docente; muestra el valor de feedback y data para instrucción.

6.3 Por qué el estudio de Kestin no debe generalizarse mecánicamente

- La comparación es valiosa: mismo curso, crossover, contenido comparable, gran efecto y menos tiempo. Pero el tutor fue diseñado por expertos para dos lecciones, con materiales detallados, soluciones preescritas, control externo de la secuencia y estudiantes de Harvard.
- No mide curso completo, uso voluntario, delayed retention, transferencia distante, costo de autoría experta o desempeño en población heterogénea. El efecto identifica una receta muy cuidada, no “usar un chatbot”.
- Su mayor contribución es de diseño: self-pacing, active learning, cognitive load, growth mindset, scaffolding, accuracy y feedback pueden codificarse; y la plataforma debe controlar la secuencia cuando el prompt no basta.

6.4 La lección de Bastani: rendimiento asistido versus capital humano

El estudio muestra una frontera conceptual. Una herramienta puede aumentar output contemporáneo —problemas resueltos durante la sesión— y reducir el stock de habilidad que queda cuando desaparece. Económicamente, la asistencia funciona como capital complementario en la tarea actual, pero puede sustituir el esfuerzo de formación. La evaluación debe separar productividad conjunta y capacidad propia.

GPT Tutor redujo el daño mediante prompts con solución y errores comunes, prohibición de revelar la respuesta y uso de pistas. No produjo una ventaja autónoma clara, lo que sugiere que evitar sustitución cognitiva es condición necesaria, no suficiente. La siguiente generación debe optimizar transferencia demorada y calibrar cuándo retirar apoyo.

INFORME COMPLETO

SECCIÓN

7. Por qué algunos sistemas funcionan y otros no

Mecanismos de diseño, comportamiento e implementación que explican la heterogeneidad.

Mecanismo	Configuración favorable	Fallo típico
Alineamiento curricular	La tarea, explicación y evaluación pertenecen al mismo mapa de competencias.	Chat genérico que introduce contenido irrelevante o una convención distinta.
Diagnóstico útil	Señales estructuradas, preguntas discriminantes y misconceptions conocidos.	Inferencia por estilo verbal, memoria cruda o etiquetas psicológicas no validadas.
Secuencia controlada	La plataforma impone etapas, prerequisites y límites; el LLM verbaliza.	Prompt único que espera obediencia perfecta durante una conversación larga.
Contenido verificado	Worked solutions, bancos de ítems, herramientas y fuentes autorizadas.	Generación libre de problemas/soluciones sin validación.
Esfuerzo protegido	Attempt-first, pistas graduadas, self-explanation y fading.	Respuesta inmediata, completar tareas o elogio sin comprobación.
Feedback accionable	Localiza el error y su causa, luego ofrece una acción adecuada.	Feedback genérico, excesivo o con demasiados pasos.
Uso suficiente	Tiempo reservado, docente/facilitador, recordatorios y seguimiento.	Licencia disponible pero uso optativo y sin accountability.
Rol humano claro	Docente fija objetivos, interpreta datos, motiva y escala.	Panel ruidoso o automatización que desplaza responsabilidad.
Medición honesta	Prueba sin ayuda, delayed transfer, costo y heterogeneidad.	Satisfacción, chats, tareas terminadas o evaluación generada por el mismo sistema.

7.1 La dosificación es endógena

- El uso depende de motivación, fricción de login, disponibilidad de dispositivo, horario, apoyo, percepción de valor y dificultad. Quienes más podrían beneficiarse pueden ser quienes menos entran o usan superficialmente.

- Un análisis intención-a-tratar responde qué ocurre al ofrecer el sistema; un análisis de tratamiento recibido requiere supuestos y debe reportarse como tal. Para política pública importan ambos: eficacia bajo uso y efectividad bajo adopción real.
- Los diseños deben registrar minutos activos, número y tipo de interacciones, cumplimiento de secuencia, interrupciones y exposición humana. “Cuenta creada” o “mensaje enviado” no es dosificación.

7.2 La calidad del modelo es una condición, no el outcome

Benchmarks de pedagogía, factualidad o preferencia experta ayudan a filtrar modelos. LearnLM reporta ventajas de preferencia pedagógica frente a modelos generales [17]; Eedi auditó errores y edición [7]. Pero un mensaje mejor no asegura que el alumno actúe sobre él. Niousha et al. proponen añadir una dimensión conductual: qué hace el estudiante con el feedback y si lo aplica correctamente [31].

7.3 Heterogeneidad y equidad

- Sistemas adaptativos pueden beneficiar a alumnos rezagados al enseñar al nivel real; también pueden mantener expectativas bajas si el criterio de avance o el contenido disponible es limitado.
- Sierra Leona encontró mayor beneficio entre estudiantes con mejor línea base [5]. Esto puede reflejar literacy/digital skills, capacidad de formular preguntas o complementariedad con conocimientos previos. El diseño debe medir y compensar esas barreras.
- La flexibilidad lingüística ayuda a contextos multilingües, pero traducción fluida no garantiza fidelidad conceptual ni adecuación cultural. Se requieren corpus locales, revisión, docentes y evaluaciones en la lengua pertinente.
- La personalización basada en atributos demográficos puede reforzar estereotipos. Conviene adaptar a evidencia de desempeño y preferencias explícitas, auditar disparidades y permitir corrección.

7.4 Costo de autoría versus costo marginal

El costo marginal de generar una respuesta puede ser bajo, pero un sistema serio exige mapeo curricular, ítems, soluciones, verificación, integración, privacidad, observabilidad, soporte, capacitación, dispositivos y experimentación. Las cifras de costo por tutor o alumno que omiten infraestructura y autoría no son comparables. El costo relevante es total y debe expresarse por alumno servido y por ganancia de aprendizaje, con sensibilidad a escala y uso.

INFORME COMPLETO

SECCIÓN

8. Riesgos, fallos y gobernanza

Los riesgos educativos no se reducen a alucinaciones: incluyen dependencia, inequidad, pérdida de agencia y mala medición.

Riesgo	Modo de fallo	Control
Error factual o procedimental	Explicación plausible pero falsa; solución incorrecta; cita inventada.	Grounding, herramientas, validación, abstención, sampling audit y canal de reporte.
Sobreasistencia	El alumno copia, delega o deja de recuperar; mejora con IA y empeora sin ella.	Attempt-first, hint ladder, límites, fading, pruebas sin IA y detección de direct answers.
Diagnóstico falso	El sistema interpreta mal el error y adapta contenido/tono de manera dañina.	Confidence, preguntas diagnósticas, learner model interpretable, override docente y recalibración.
Sesgo y brecha	Mejores resultados para quien sabe preguntar, tiene dispositivo, idioma dominante o apoyo.	Diseño universal, facilitación, medición por subgrupo, contenido local, acceso y soporte.
Privacidad y menores	Historial cognitivo, voz, escritura y conducta almacenados o usados para entrenamiento.	Minimización, finalidad, retención, consentimiento, aislamiento, borrado y contratos auditables.
Integridad evaluativa	Producción externa sustituye desempeño; imposible interpretar tareas tradicionales.	Modos de uso, evaluaciones auténticas/orales, proceso, trazabilidad y rediseño del assessment.
Automatización docente	Confianza excesiva en recomendaciones, rúbricas o clasificación; deskilling.	Human-in-command, explicaciones, muestreo, calibración, formación y responsabilidad clara.
Antropomorfismo/vínculo	Confianza, dependencia emocional o persuasión indebida.	Lenguaje transparente, límites relacionales, no simular autoridad/conciencia, escalamiento humano.

Riesgo	Modo de fallo	Control
Lock-in y opacidad	Learner model y logs no portables; modelo cambia sin evaluación.	Interoperabilidad, exportación, versionado, notice, benchmarks contractuales y planes de salida.
Optimización equivocada	Engagement, velocidad o satisfacción desplazan aprendizaje y autonomía.	Outcome hierarchy preregistrada y guardrails de no regresión.

8.1 Privacidad del learner model

El learner model puede revelar más que una nota: patrones de error, velocidad, persistencia, confianza, idioma, discapacidad inferida, temas sensibles y relación con docentes. Debe tratarse como dato educativo de alta sensibilidad. La institución necesita saber qué campos existen, quién accede, cuánto se retienen, si alimentan entrenamiento, cómo se corrigen y cómo se exportan o borran.

8.2 Gobernanza de cambios de modelo

Un producto puede cambiar de modelo, prompt, filtros o herramientas sin que el nombre de la interfaz cambie. Cada versión relevante debe registrarse; los outcomes y auditorías deben vincularse a versión, fecha, configuración, contenido y política. Una mejora de benchmark no debe autorizar automáticamente un despliegue mayor sin pruebas de no regresión pedagógica y de seguridad.

8.3 La transparencia útil

Audiencia	Información mínima
Para el alumno	Qué puede/no puede hacer; cuándo puede equivocarse; qué datos usa; por qué pide un esfuerzo; cómo pedir humano.
Para el docente	Objetivo, contenido recuperado, estado estimado, confianza, política, historial y motivo de alerta.
Para la institución	Arquitectura, proveedores, retención, versiones, incidentes, métricas, sesgo, costos, SLAs y salida.
Para el investigador	Asignación, attrition, dosage, prompts, model version, outcomes, análisis, datos/código cuando sea posible.

INFORME COMPLETO

SECCIÓN

9. Cómo medir si un sistema enseña

Marco de outcomes, diseño experimental y métricas de proceso.

9.1 Jerarquía de outcomes

Nivel	Medida	RoI
1. Aprendizaje autónomo	Prueba independiente, sin IA, alineada pero no idéntica; scoring ciego cuando sea posible.	Primario.
2. Retención	Misma competencia después de días/semanas; recuperación sin apoyo.	Primario o coprimario.
3. Transferencia	Problemas nuevos, tema posterior, contexto distinto o tarea auténtica.	Clave para generalización.
4. Eficiencia	Tiempo a dominio, oportunidades, costo y aprendizaje por hora.	No sustituye calidad.
5. Proceso	Intentos, pistas, self-explanation, error correction, direct-answer rate, persistencia y profundidad.	Mecanismo/diagnóstico.
6. Autonomía/metacognición	Calibración, planificación, elección de estrategia, motivación autónoma y dependencia.	Necesario para efectos largos.
7. Equidad	Efectos, uso, errores y acceso por nivel inicial, lengua, género, SES, discapacidad y contexto.	No solo promedio.
8. Docente/sistema	Carga, calidad, decisiones, cobertura, relaciones, incidentes, adopción y fidelidad.	Implementación.

9.2 Diseño mínimo recomendado

Elemento	Estándar
Pregunta	Definir tratamiento como sistema + protocolo + soporte; no “usar IA”.
Comparador	Control activo con igual tiempo, contenido, atención, dispositivo y posibilidad de pedir ayuda cuando sea viable.
Asignación	Randomización individual o cluster; preregistro; balance; plan de attrition y spillovers.
Duración	8–16 semanas o curso; medir evolución. Estudios cortos sirven para mecanismo, no para efectividad general.
Evaluación	Outcome creado/administrado independientemente; sin acceso a IA; prueba demorada y de transferencia.
Dosificación	ITT + uso real; minutos activos, sesiones, pasos, adherencia, calidad y exposición humana.
Procesos	Logs con taxonomía validada; muestras revisadas por expertos; student action after feedback.
Heterogeneidad	Preespecificar subgrupos y evitar fishing; analizar quién no usa y por qué.
Costos	Costeo ingredientes: modelo, autoría, hardware, conectividad, formación, supervisión, soporte y administración.
Reproducibilidad	Versiones, prompts, contenido, código, instrumentos, decisiones y cambios durante el estudio.

9.3 Métricas de proceso que sí importan

Métrica	Definición
Productive engagement rate	Proporción de turnos con razonamiento, generación, corrección o explicación; no solo lectura/copia.
Direct-answer rate	Frecuencia con que el sistema o alumno busca/entrega la solución antes de trabajo suficiente.
Hint dependence	Pistas por éxito, success-without-hint posterior y velocidad de fading.
Error repair	Probabilidad de identificar, explicar y no repetir el mismo error.
Calibration	Correspondencia entre confianza y desempeño; del alumno y del tutor.
Next-item transfer	Éxito en ítem nuevo de la misma habilidad sin ayuda; útil como leading indicator, no outcome final.
Topic coverage	Dominio, profundidad y diversidad; evitar concentración en lo fácil o solicitado.
Adoption/fidelity	Login, minutos activos, sesiones completas, cumplimiento docente, latencia e incidentes.

Khan Academy usa next-item correctness como medida inmediata de transferencia [13]. Es superior a medir solo satisfacción o éxito con ayuda, pero no reemplaza un examen independiente ni retención. OpenAI propone graders longitudinales y medidas cognitivas/metacognitivas [14]; deben validarse contra datos humanos y evitar que el mismo modelo sea juez de su propio impacto.

9.4 Diseño factorial para abrir la caja negra

Cuando sea posible, un experimento factorial puede separar: (a) diálogo generativo versus feedback estático; (b) learner model sí/no; (c) guardrails sí/no; (d) docente/coach sí/no; (e) secuencia externa versus control LLM; (f) herramienta verificada versus generación sola. Esto estima componentes y complementariedades, aunque requiere muestras grandes. La alternativa práctica es iterar con A/B de proceso y confirmar los cambios acumulados en un RCT de outcome independiente.

INFORME COMPLETO

SECCIÓN

10. Cómo seleccionar o diseñar un sistema

Una rúbrica para instituciones, investigadores y equipos de producto.

Criterio	Qué exigir	Escala rápida
Objetivo y población	Competencias, edad, idioma, contexto, accesibilidad, duración y papel humano definidos.	0: genérico; 1: parcial; 2: preciso y validado.
Currículo/dominio	Mapa de conceptos, prerequisites, fuentes, ítems, soluciones y criterios de dominio.	0: web libre; 1: RAG; 2: dominio estructurado y auditado.
Learner model	Variables, actualización, incertidumbre, corrección, portabilidad y evidencia predictiva.	0: chat; 1: resumen; 2: mastery/misconception calibrado.
Política pedagógica	Acciones, reglas de ayuda, secuencia, fading, escalamiento y objetivo explícito.	0: prompt; 1: reglas; 2: policy testada y observable.
Verificación	Tools, citations, solutions, confidence, abstention, auditoría y error rates.	0: ninguna; 1: parcial; 2: independiente/medida.
Control humano	Asignar, ver, corregir, limitar, intervenir y exportar; alertas accionables.	0: ausente; 1: dashboard; 2: human-in-command.
Seguridad/privacidad	Datos, menores, retención, entrenamiento, bias, incidentes y contrato.	0: opaco; 1: compliance; 2: minimización + auditoría.
Evidencia	Outcome sin ayuda, duración, comparador, versión, población, heterogeneidad y réplica.	0: testimonios; 1: telemetría; 2: causal relevante.
Implementación	Dosificación, capacitación, soporte, dispositivos, latencia, uptime y workflow.	0: licencia; 1: plan; 2: fidelity observada.
Economía/salida	Costo total, costo por gain, interoperabilidad, exportación y plan de discontinuación.	0: precio; 1: TCO; 2: TCO + efectividad + salida.

Regla de decisión. No comprar por “modelo de frontera”, cantidad de funciones o demostración. Comprar —o construir— cuando la arquitectura sea visible, la política sea compatible con el objetivo, la implementación sea viable y la evidencia mida el mismo outcome, población y modo de uso.

10.1 Preguntas para una demo técnica

- Muestre el learner model de un alumno ficticio antes y después de tres respuestas. ¿Qué cambió y por qué?
- Fuerce un error factual, una respuesta ambigua y una solicitud de “solo dame la respuesta”. ¿Qué rutas activa?
- Cambie el objetivo curricular o la convención matemática. ¿Cómo se controla la fuente y se evita mezclar marcos?
- Muestre una conversación larga con cambio de tema. ¿Quién controla la secuencia y qué ocurre si el LLM ignora una regla?
- Abra el panel docente. ¿Qué acción concreta sugiere, qué evidencia ofrece y cómo se corrige una inferencia?
- Exporte logs, versiones, contenido recuperado, incidentes y métricas por subgrupo. ¿Qué no puede exportarse?
- Explique qué parte del producto fue evaluada, con qué versión, en qué población y con qué prueba sin ayuda.
- Calcule el costo total con la dosis recomendada, capacitación, soporte, devices y supervisión; no solo tokens/licencia.

10.2 Arquitectura recomendada para un piloto

Fase	Entregable
Fase 0: diseño	Seleccionar 1–3 competencias, currículo autorizado, población, outcome y protocolo humano.
Fase 1: tutor constrained	RAG + banco/solutions + learner model simple + policy externa + logs + override.
Fase 2: validación	Red-team, factuality, pedagogical rubric, privacidad, accesibilidad y small usability.

Fase	Entregable
Fase 3: piloto causal	Control activo, 8–16 semanas, medición sin ayuda, dosage y costo.
Fase 4: scale gate	Escalar solo si no hay regresión en aprendizaje, equidad, seguridad y carga; repetir con nueva versión.

INFORME COMPLETO

SECCIÓN

11. Frontera 2026-2030

Qué avances son plausibles y qué sigue sin demostrarse.

Frontera	Promesa	Pregunta abierta
Learner models persistentes y portables	Memoria estructurada entre cursos y herramientas, con dominio, olvido, metas y privacidad.	Interoperabilidad, corrección, gobernanza y validación longitudinal.
Agentes pedagógicos	Planner coordina tutor, evaluador, simulador, buscador, solver y docente.	Control, errores compuestos, costo/latencia y trazabilidad.
Multimodalidad auténtica	Observa escritura, habla, diagramas, laboratorio y pantalla; feedback situado.	Privacidad, validez de percepción y evaluación de tareas abiertas.
Políticas aprendidas por outcomes	Bandits/RL eligen próxima intervención usando transferencia y retención.	Recompensa correcta, exploración ética, drift y generalización.
Generación curricular validada	Produce ítems, distractores, ejemplos y simulaciones calibradas automáticamente.	Control de dificultad, cobertura, copyright, bias y leakage.
Copilotos de aula	Agrupamiento, alertas, explicación de errores y sugerencias durante clase.	Sobrecarga, confianza, workflow y downstream impact.
Evaluación continua	Evidencia de proceso, conversación oral, proyectos y performance, no solo examen final.	Validez, privacidad, comparabilidad e incentivos.
Tutoría de bajo costo global	Voz/móvil/offline, lenguas locales, currículo nacional y facilitadores.	Infraestructura, soporte, contenido local y capacidad estatal.

11.1 Lo que probablemente veremos

- Convergencia entre ITS y LLM: los sistemas generativos incorporarán mastery, prerequisite graphs y schedulers; los adaptativos añadirán diálogo, voz y generación de contenido.
- Más arquitectura “constrained”: modelos dentro de flujos, herramientas y políticas, con libertad local y control global. La mejora vendrá tanto del sistema como del foundation model.
- Copilotos para adultos antes que autonomía plena: es más fácil medir y controlar una sugerencia a un tutor/docente que delegar toda la interacción con menores.
- Medición de conducta y longitudinalidad: la industria pasará de “mensaje pedagógicamente bueno” a acciones del alumno, retención, dependencia y trayectorias. Los estudios nacionales en Estonia y nuevos RCT de Eedi son señales [14,30].
- Presión por interoperabilidad y soberanía: instituciones querrán controlar contenido, learner models, logs, versiones y capacidad de cambiar de proveedor.

11.2 Lo que no está demostrado

- Que un tutor generativo autónomo produzca, a escala y durante cursos completos, resultados equivalentes o superiores a tutoría humana de alta calidad.
- Que la personalización conversacional mejore outcomes por encima de secuenciación adaptativa clásica, manteniendo constantes contenido, tiempo y soporte.
- Que los gains inmediatos persistan, transfieran a tareas lejanas y no reduzcan autonomía, motivación o capacidad de trabajar sin herramienta.
- Que los costos totales —incluyendo infraestructura, autoría, supervisión, privacidad y soporte— sean sistemáticamente menores por unidad de aprendizaje.
- Que las ventajas se distribuyan equitativamente sin facilitación, alfabetización digital, accesibilidad y contenido local.

Agenda científica. La pregunta ya no es “¿puede conversar como tutor?”. Es: ¿qué estado del alumno mantiene, qué política elige, qué parte del esfuerzo conserva, qué componente produce el gain, para quién, cuánto dura y a qué costo?

INFORME COMPLETO

SECCIÓN

12. Conclusiones

Una síntesis directa para investigación, diseño y política educativa.

1	1. Un buen sistema de IA educativa es una institución en miniatura. — Tiene currículo, diagnóstico, reglas, instrumentos, roles, registros y accountability. El LLM es un componente de interfaz y razonamiento, no la institución completa.
2	2. La personalización útil es una decisión contrafactual. — El sistema debe poder mostrar que, ante evidencia distinta del alumno, habría escogido otra tarea o ayuda y que esa diferencia mejora outcomes. Personalizar estilo sin cambiar intervención es superficial.
3	3. La evidencia promedio es positiva, no definitiva. — +0.125 DE es relevante, pero proviene de pocos RCT heterogéneos. La generación no ha demostrado superioridad general sobre tecnología adaptativa previa.
4	4. Los grandes efectos son recetas, no propiedades del modelo. — Harvard, Nigeria y Sierra Leona combinan diseño curricular, secuencia, docentes, tiempo y soporte. Copiar la marca o el prompt no reproduce el tratamiento.
5	5. El outcome crítico es capacidad sin ayuda. — El caso Bastani obliga a medir capital humano después de retirar la herramienta. Productividad conjunta y aprendizaje pueden moverse en direcciones opuestas.
6	6. La política pedagógica debe ser externa y auditable en decisiones críticas. — Prompts son útiles para estilo y realización; el orden, answer withholding, mastery gates y escalamiento requieren controles más deterministas.
7	7. El híbrido humano-IA es la estrategia de menor arrepentimiento. — La IA puede estandarizar buenas preguntas, ofrecer explicaciones y ampliar alcance; el humano sostiene objetivos, motivación, contexto, relaciones y responsabilidad.
8	8. La dosificación y la implementación son parte del modelo causal. — Un sistema al que nadie entra no tiene efecto. La evaluación debe incluir adopción, fidelidad, infraestructura y workflow.

9

9. La gobernanza debe cubrir el learner model y el cambio de versión. — No basta una política general de privacidad. Se necesitan datos mínimos, corrección, exportación, versionado, auditoría y pruebas de no regresión.

10

10. La compra debe condicionarse a evidencia relevante. — Misma población, objetivo, modo de uso, outcome sin asistencia y costo total. La demostración más fluida puede ser el sistema menos educativo si elimina el esfuerzo que se quería formar.

Conclusión final

Los sistemas modernos ya pueden hacer que una interacción educativa sea mucho más flexible, accesible y sensible al alumno. La evidencia sugiere que pueden mejorar aprendizaje cuando la IA está subordinada a una arquitectura pedagógica, contenido verificable, fricción productiva y conducción humana. El avance decisivo no será un chatbot que “suena” más como profesor, sino un sistema que sabe qué intenta enseñar, qué cree que el alumno sabe, por qué elige la siguiente intervención, cuándo debe callar o pedir ayuda y cómo demuestra —sin ser juez de sí mismo— que el estudiante aprendió.

INFORME COMPLETO

SECCIÓN

Apéndice A. Matriz comparativa de sistemas

Capacidades visibles y solidez de la evidencia pública; valoración cualitativa al corte del informe.

Sistema	Currículo	Learner model	Policy	GenAI/multi	Guardrails	Humano	Evidencia	Nota
Khanmigo	Alta	Media-alta	Alta	Alta	Alta	Alta	C/B	Currículo + A/B de producto
ChatGPT Study Mode	Media	Baja-media	Alta	Alta	Media	Media	B temprana	Flexible; evidencia longitudinal en desarrollo
Gemini Guided Learning	Media	Media	Alta	Alta	Media-alta	Alta	B/A emergente	RCT Sierra + Eedi supervisado
Claude Learning Mode	Media	Baja-media	Alta	Alta	Media	Media	D/C	Capacidad clara; outcomes causales no públicos
MATHia	Alta	Alta	Alta	Baja-media	Alta	Alta	B/A histórica	ITS estructurado
ALEKS	Alta	Alta	Alta	Baja	Alta	Alta	B/C	Knowledge Space Theory
ASSISTments	Alta	Media	Alta	Baja	Alta	Alta	A	Software + teacher data/PD
Mindspark	Alta	Alta	Alta	Baja	Alta	Media	A	Fuerte benchmark pre-LLM
Eedi/LearnLM	Alta	Media-alta	Alta	Alta	Alta	Alta	B	Human-supervised constrained AI
Tutor CoPilot	Alta	Indirecta	Alta	Media	Alta	Muy alta	A/B	Copilot, no tutor autónomo
Duolingo	Alta	Alta	Alta	Alta	Alta	Baja-media	C/D capa GenAI	Híbrido adaptativo-generativo
Rori	Alta	Media	Alta	Media	Media	Media-alta	B	WhatsApp/baja conectividad

Escala: “Alta” significa que la función es central y observable en la descripción/implementación; no implica calidad causal. Grados A–D siguen la jerarquía del informe. La ausencia de evidencia pública no prueba ausencia de efecto.

INFORME COMPLETO

SECCIÓN

Apéndice B. Matriz de evidencia

Qué outcome mide cada estudio y qué afirmación permite sostener.

Fuente	Diseño	Outcome	Sin IA	Horizonte	Conclusión permitida
Burneo et al. 2026	Meta-análisis RCT	Aprendizaje, no-learning, docente	Sí, estudios incluidos	Variable	Promedio +0.125 DE; no ranking robusto entre tecnologías
Bastani et al. 2025	RCT	Práctica + examen	Sí	Corto	Guardrails evitan daño de GPT irrestricto
Kestin et al. 2025	Crossover RCT	Post-test inmediato	Sí	2 lecciones	Tutor diseñado supera active learning en ese contexto
De Simone et al. 2025	RCT	Pen-and-paper + skills	Sí	6 semanas	Paquete teacher-led after-school efectivo
Sierra Leona 2026	Cluster RCT	Math assessment	Sí	8 semanas	Guided Learning teacher-led mejora math
Tutor CoPilot	RCT	Mastery plataforma + estrategias	Outcome sin copilot para alumno; tutor lo usa	Programa	Copilot mejora tutoría, sobre todo tutores débiles
Eedi/LearnLM	Exploratory RCT	Corrección, misconception, next-topic	Sí, después de intervención	Sesiones	AI supervisada al menos comparable; señal de transfer
Robinson et al. 2026	2 RCT	Uso + reading	Sí	14-31 semanas	Acceso solo no produce dosis; humano sube uso, no gains
Rori Ghana	Preliminar/cuasi	Math growth	Sí	8 meses	Señal grande, identificación/extra time cautela
Mindspark	Lottery RCT	Math/Hindi test	Sí	4.5 meses	Adaptativo clásico con efecto grande
ASSISTments	Cluster RCT	Standardized math	Sí	2 años	Feedback + teacher data mejora math
Khanmigo A/B	Experimentos producto	Next-item correctness/engagement	Siguiente ítem sin Khanmigo	Minutos/sesión	Evidencia de componentes, no impacto de curso
OpenAI Study Mode	RCT temprano	Exámenes universitarios	Sí	Sesiones pre-examen	Heterogéneo por materia; análisis en curso

INFORME COMPLETO

SECCIÓN

Apéndice C. Glosario operacional

Términos empleados en el informe.

Término	Definición
Adaptive learning	Sistema que cambia contenido, dificultad, secuencia o apoyo a partir de evidencia del alumno.
AI tutor	Sistema que realiza funciones tutoriales; puede ser generativo, simbólico, estadístico o híbrido.
Answer withholding	Política que evita entregar la solución antes de intento o evidencia suficiente.
BKT / Knowledge Tracing	Modelo probabilístico de dominio latente actualizado mediante observaciones de desempeño.
Deep Knowledge Tracing	Uso de modelos de secuencia/neuronales para predecir desempeño y estado de conocimiento.
Fading	Retirada gradual de pistas o soporte a medida que aumenta competencia.

Término	Definición
Grounding	Vincular generación a fuentes, contenido o herramientas externas autorizadas.
Guardrail pedagógico	Restricción diseñada para preservar aprendizaje, integridad o seguridad.
Hint ladder	Secuencia de pistas de menor a mayor explicitud.
Human-in-the-loop	Humano revisa, aprueba o interviene dentro del flujo.
Human-in-command	Humano conserva autoridad, objetivos, límites y responsabilidad, aunque no revise cada output.
Learner model	Representación estructurada del estado, historial y necesidades del alumno.
Mastery learning	Progresión condicionada a alcanzar un criterio de dominio.
Next-item correctness	Desempeño en el siguiente ítem de la misma habilidad sin ayuda; leading indicator de transfer cercana.
Policy / planner	Componente que elige la próxima intervención pedagógica.
Productive struggle	Esfuerzo y dificultad que generan procesamiento útil sin bloqueo improductivo.
RAG	Recuperación de información relevante para fundamentar la generación.
Scaffolding	Soporte temporal que permite realizar una tarea y se ajusta/retira con progreso.
Transferencia cercana/lejana	Aplicar aprendizaje a tareas similares/novedosas o contextos distintos.
Worked example	Solución completa explicada que reduce carga y muestra procedimiento.

INFORME COMPLETO

SECCIÓN

Referencias

Fuentes primarias, documentación oficial y síntesis utilizadas.

- [1] Burneo, A., Dinarte-Díaz, L., Lopez, C. y Molina, E. (2026). Can EdTech Close Learning Gaps? Global Evidence from Digital Interventions. Banco Mundial, 1 de agosto de 2026. [Fuente](#)
- [2] Kestin, G. et al. (2025). AI tutoring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educational setting. Scientific Reports, 15, 17458. [Fuente](#)
- [3] Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakci, O. y Mariman, R. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. PNAS. [Fuente](#)
- [4] De Simone, M. E. et al. (2025). From Chalkboards to Chatbots: Evaluating the Impact of Generative AI on Learning Outcomes in Nigeria. World Bank Policy Research Working Paper 11125. [Fuente](#)
- [5] LearnLM Team, Google DeepMind y Fab AI (2026). Teaching with Gemini: Measuring the impact of Guided Learning on student mathematics progress in Sierra Leone. Technical report. [Fuente](#)
- [6] Wang, R. E., Ribeiro, A. T., Robinson, C. D., Loeb, S. y Demszy, D. (2024). Tutor CoPilot: A Human-AI Approach for Scaling Real-Time Expertise. [Fuente](#)
- [7] LearnLM Team y Eedi (2025). AI tutoring can safely and effectively support students: An exploratory RCT in UK classrooms. [Fuente](#)
- [8] Robinson, C. D., Gormley, D., Ribeiro, A. T. y Loeb, S. (2026). Access is Not Enough: Human Support Improves Engagement with AI Tutoring. [Fuente](#)
- [9] Henkel, O., Horne-Robinson, H., Kozhakhmetova, N. y Lee, A. (2024). Effective and Scalable Math Support: Experimental Evidence on the Impact of an AI-Math Tutor in Ghana. [Fuente](#)
- [10] Muralidharan, K., Singh, A. y Ganimian, A. J. (2019). Disrupting Education? Experimental Evidence on Technology-Aided Instruction in India. American Economic Review, 109(4), 1426-1460. [Fuente](#)
- [11] Roschelle, J., Feng, M., Murphy, R. F. y Mason, C. A. (2016). Online Mathematics Homework Increases Student Achievement. AERA Open. [Fuente](#)
- [12] Nickow, A., Oreopoulos, P. y Quan, V. (2024). The Promise of Tutoring for PreK-12 Learning: A Systematic Review and Meta-Analysis of the Experimental Evidence. AERJ, 61(1), 74-107. [Fuente](#)
- [13] Khan Academy (2026). How Khan Academy Is Building a Better AI Tutor: Our Most Recent Learnings. [Fuente](#)
- [14] OpenAI (2026). New tools for understanding AI and learning outcomes. [Fuente](#)

- [15] Anthropic (2025). Introducing Claude for Education. [Fuente](#)
- [16] Google (2025). Guided Learning in Gemini. [Fuente](#)
- [17] LearnLM Team (2024). LearnLM: Improving Gemini for Learning. [Fuente](#)
- [18] ALEKS. Research Behind ALEKS: Knowledge Space Theory. [Fuente](#)
- [19] Carnegie Learning. MATHia adaptive mathematics software. [Fuente](#)
- [20] Duolingo (2023). Duolingo Max Uses GPT-4 for Roleplay and Explain My Answer. [Fuente](#)
- [21] Ma, W., Adesope, O. O., Nesbit, J. C. y Liu, Q. (2014). Intelligent Tutoring Systems and Learning Outcomes: A Meta-Analysis. Journal of Educational Psychology, 106(4), 901-918. [Fuente](#)
- [22] Corbett, A. T. y Anderson, J. R. (1994). Knowledge tracing: Modeling the acquisition of procedural knowledge. User Modeling and User-Adapted Interaction, 4, 253-278. [Fuente](#)
- [23] Piech, C. et al. (2015). Deep Knowledge Tracing. Advances in Neural Information Processing Systems. [Fuente](#)
- [24] OpenAI (2025). ChatGPT Study Mode. [Fuente](#)
- [25] Khan Academy. Khan Labs / Khanmigo. [Fuente](#)
- [26] ASSISTments. Evidence and platform description. [Fuente](#)
- [27] Burns, M. (2026). What the research shows about generative AI in tutoring. Brookings Institution. [Fuente](#)
- [28] Létourneau, A. et al. (2025). A systematic review of AI-driven intelligent tutoring systems in K-12 education. [Fuente](#)
- [29] OpenAI. ChatGPT release notes: Study mode availability and behavior. [Fuente](#)
- [30] Eedi (2026). Second constrained AI Tutor RCT: four arms, 1,525 students, ten schools. [Fuente](#)
- [31] Niousha, R. et al. (2026). The Missing Evaluation Axis: What 10,000 Student Submissions Reveal About AI Tutor Effectiveness. [Fuente](#)
- [32] Chen, Y. et al. (2026). Not All Students Engage Alike: Multi-Institution Patterns in GenAI Tutor Use. [Fuente](#)
- [33] UNESCO (2023). Guidance for Generative AI in Education and Research. [Fuente](#)
- [34] Khan Academy (2026). Learning in the open: what AI is and is not changing. [Fuente](#)
- [35] Anthropic (2025). Anthropic Education Report: How educators use Claude. [Fuente](#)
- [36] Anthropic (2025). Anthropic Education Report: How university students use Claude. [Fuente](#)
- [37] Google DeepMind (2026). Measuring the impact of learning with AI in Sierra Leone and beyond. [Fuente](#)
- [38] World Bank (2025). Reproducibility package for From Chalkboards to Chatbots. [Fuente](#)