

IA generativa para aprender y enseñar mejor

Sistemas modernos, arquitectura, evidencia causal y agenda de evaluación

Corte de evidencia: 10 de agosto de 2026

Tesis central. La unidad relevante no es el modelo de lenguaje, sino el sistema pedagógico completo: currículo verificable, modelo del estudiante, política de tutoría, herramientas, límites, conducción humana y medición independiente.

+0.125 DE efecto medio 14 RCT; 191 estimaciones	0.12 DE tutoría/instrucción IA promedio metaanalítico	No probado GenAI > adaptativo clásico diferencia imprecisa
---	---	---

La conclusión en una frase

Los mejores resultados aparecen cuando la IA está encajada dentro de una secuencia didáctica estructurada, exige esfuerzo cognitivo, usa contenido comprobado, entrega información accionable al docente y se evalúa con pruebas sin asistencia; el “chat inteligente” genérico no ofrece esas garantías.

SEIS CONCLUSIONES DECISIVAS

1	El modelo no es el tutor — Un LLM solo genera lenguaje. La personalización profunda requiere estado de dominio, prerrequisitos, historial, objetivos, política de intervención y evaluación.
2	La evidencia es positiva, pero no milagrosa — El metaanálisis más reciente estima +0.125 DE; la gran heterogeneidad impide convertir un resultado espectacular en una regla general.
3	Ayuda no equivale a aprendizaje — La métrica crítica es desempeño posterior sin IA, idealmente demorado y en tareas nuevas. Sin guardrails, la asistencia puede elevar la práctica y reducir el examen autónomo.
4	La pedagogía debe controlar la IA — Secuencias, hint ladders, solución verificada, “intento antes de pista” y retirada gradual son más confiables que un prompt socrático genérico.
5	El híbrido humano-IA es la apuesta inmediata — Docentes y tutores sostienen objetivos, motivación, diagnóstico social, seguridad y uso suficiente; la IA amplía capacidad y consistencia.
6	La adopción es una variable causal — Dar acceso no garantiza uso. En dos RCT recientes, muchos alumnos casi no interactuaron; sin dosificación, no hay tratamiento real.

ARQUITECTURA DE REFERENCIA

El “tutor” moderno es una pila de ocho capas

La conversación es solo la superficie. La calidad pedagógica depende de lo que el sistema sabe del dominio y del alumno, de cómo decide la próxima intervención y de cómo comprueba sus propios resultados.

Capa	Función	Qué debe contener
1	Modelo del dominio	Currículo, estándares, conceptos, prerrequisitos, ejemplos resueltos y criterios de dominio.
2	Modelo del estudiante	Estimación de conocimiento, errores, intentos, confianza, ritmo y trayectoria; no solo “memoria del chat”.
3	Política pedagógica	Decide preguntar, dar pista, explicar, practicar prerrequisito, cambiar dificultad o retirar ayuda.
4	Generación + multimodalidad	Diálogo, voz, imagen, simulación, role-play y explicaciones en distintas representaciones.
5	Grounding y herramientas	RAG sobre materiales autorizados; calculadora, solver, código, búsqueda, verificadores y citas.
6	Guardrails de aprendizaje	No revelar la respuesta, requerir intento, graduar pistas, detectar copia, incertidumbre y contenido riesgoso.
7	Orquestación humana	Asignaciones, panel docente, alertas, agrupamiento, aprobación de mensajes, escalamiento y seguimiento.
8	Medición	Transferencia sin ayuda, retención, tiempo a dominio, proceso, equidad, carga docente, costo y uso real.

CUATRO NIVELES DE PERSONALIZACIÓN

Nivel	Definición operativa
1. Presentación	Idioma, tono, extensión, lectura fácil. Común; impacto pedagógico limitado.
2. Interacción	Preguntas, ejemplos, pista y modalidad adaptados al turno. La mayoría de los chats modernos llega aquí.
3. Decisión pedagógica	Próxima acción basada en diagnóstico, dificultad, error y esfuerzo productivo. Requiere política explícita.
4. Trayectoria longitudinal	Dominio acumulado, prerrequisitos, espaciado, objetivos y transferencia entre sesiones. Aún poco común en LLM generalistas.
	Prueba de realidad. Un sistema que recuerda el nombre, cambia el tono o “parece empático” puede sentirse personalizado sin estimar correctamente qué sabe el alumno ni escoger la próxima tarea óptima.

MAPA 2026

Seis familias; ninguna domina todas las funciones

La frontera está convergiendo: los chats incorporan currículo y memoria; los tutores adaptativos incorporan lenguaje generativo; ambos añaden paneles docentes y verificadores.

Familia	Ejemplos	Valor distintivo	Límite actual
Tutor conversacional	Khanmigo; ChatGPT Study Mode; Gemini Guided Learning; Claude Learning Mode	Diálogo abierto, explicación, preguntas, pistas, materiales del alumno.	Alta flexibilidad; adaptación longitudinal desigual.
ITS/adaptativo estructurado	MATHia; ALEKS; ASSISTments; Mindspark	Mapa granular de habilidades, secuenciación, práctica y feedback.	Menos abierto; evidencia histórica más madura.
Híbrido GenAI + currículo	Khanmigo integrado; Eedi/LearnLM; Duolingo Max + Birdbrain	Generación dentro de una ruta, diagnóstico o banco de ítems.	Arquitectura más prometedora para personalización real.
Copiloto humano	Tutor CoPilot; asistentes de planificación y evaluación	Sugiere al tutor/docente la próxima pregunta, explicación o estrategia.	Preserva juicio humano; puede elevar a los menos expertos.
Multimodal/transformación	Reading Coach; NotebookLM; Learn Your Way; simuladores	Voz, lectura, video, mapas, cuestionarios y cambio de representación.	Útil para acceso y comprensión; efecto causal específico escaso.
Baja conectividad	Rori por WhatsApp; despliegue Nigeria; asistentes sobre textos locales	Interfaz móvil, pares, contenidos limitados, facilitador y sesiones pautadas.	Gran potencial distributivo; infraestructura y implementación mandan.

LECTURA PRECISA DE LOS PRODUCTOS MÁS VISIBLES

Sistema	Qué hay realmente detrás
Khanmigo	Integra problema, historial reciente, habilidades y prerrequisitos; usa agente matemático/verificación. A/B internos: +3.4% y +2.7% en corrección del siguiente ítem. Es transferencia inmediata de producto, no un RCT externo de aprendizaje duradero.
ChatGPT Study Mode	Instrucciones pedagógicas, andamiaje, preguntas y checks. Estudio temprano >300 universitarios: resultado positivo no significativo en neurociencia y ≈15% más en microeconomía; análisis y validación longitudinal continúan.
Gemini Guided Learning / LearnLM	Modelo ajustado para conductas pedagógicas y formato socrático. En Sierra Leona, RCT docente-dirigido +0.258 DE; el paquete incluyó capacitación, pares, lecciones y consolidación.
Claude Learning Mode	Guía, preguntas socráticas, conceptos nucleares y plantillas dentro de Projects. Hay datos de uso y despliegue universitario, pero no evidencia causal pública comparable de aprendizaje.
Duolingo	Motor adaptativo estructurado + conversación generativa, role-play y explicaciones. Buen ejemplo de hibridación; no hay estimación pública que aísle el aporte causal de la capa GenAI.

EVIDENCIA CAUSAL

La señal es favorable; las condiciones importan más que la marca

Comparar estudios exige separar práctica asistida, prueba autónoma, duración, dosificación, soporte humano, población y quién construyó/evaluó el sistema.

Estudio	Muestra/diseño	Resultado	Qué identifica realmente	Juicio
Metaanálisis 2026	14 RCT; 10 economías	+0.125 DE aprendizaje; tutoría/instrucción IA +0.12 DE	GenAI no supera con precisión a tecnología adaptativa previa; costos y países de bajos ingresos casi ausentes.	Alta síntesis; base aún pequeña
Bastani et al.	≈1,000, secundaria, Turquía	Práctica: +48% GPT Base; +127% GPT Tutor. Examen sin IA: Base −17%; Tutor ≈ control.	La asistencia irrestricta produce dependencia; guardrails eliminan el daño, no generan una ventaja autónoma.	Fuerte
Kestin et al.	194, física Harvard; 2 lecciones	≈0.63 DE; estimación ajustada por techo 0.73–1.3; 49 vs 60 min.	Sistema muy diseñado, soluciones verificadas, secuencia controlada; resultado inmediato y contexto selectivo.	Fuerte pero estrecha
Nigeria	1,328; 6 semanas; after-school	+0.31 DE compuesto; ≈+0.24 DE inglés.	GPT-4 + tiempo adicional + docente + trabajo en pares + prompting. Efecto del paquete, no del modelo solo.	Prometedora/fuerte
Sierra Leona	1,763; 12 escuelas; 8 semanas	+0.258 DE ITT.	Docente al centro; exposición alta; reporte asociado al proveedor; beneficio mayor para alumnos de línea base alta.	Prometedora
Tutor CoPilot	900 tutores; 1,800 alumnos	+4 pp dominio; +9 pp con tutores de menor rating.	La IA asesora al humano; outcome de plataforma, no test amplio.	Fuerte para copilot
Eedi/LearnLM	165; Reino Unido	+5.5 pp en problemas de tema posterior vs tutor humano; intervalos exploratorios.	Cada mensaje supervisado por expertos; 74–76% requirió cero o mínimos cambios.	Exploratoria
Acceso sin apoyo	≈350; 2 RCT de lectura	Uso +1 a +4.4 min/sem con humano; sin mejora de lectura.	Muchos nunca entraron; dosificación muy inferior a la recomendada.	Fuerte para adopción

Regla de oro de medición. El outcome principal debe ser una prueba independiente, sin IA y preferentemente demorada; después se añaden transferencia lejana, tiempo a dominio, engagement productivo, equidad y costo. “Resolvió más con ayuda” es una métrica de productividad, no de aprendizaje.

Por qué los efectos difieren

- Contenido verificado y solución conocida frente a conversación abierta; secuencia externa frente a prompt frágil.
- Intento, pista gradual y fading frente a respuesta inmediata; objetivos de dominio frente a satisfacción del usuario.
- Uso obligatorio/acompañado frente a acceso voluntario; minutos reales y fidelidad de implementación.
- Prueba inmediata y estrecha frente a retención y transferencia; estudiantes/contextos muy distintos.

DECISIÓN Y EVALUACIÓN

Exigir un sistema pedagógico auditable, no una demostración impresionante

La compra o el diseño debe comenzar con el resultado de aprendizaje y el papel del docente; después se elige el modelo y la interfaz.

DIEZ REQUISITOS NO NEGOCIABLES

#	Requisito	Prueba que debe mostrar el proveedor/equipo
1	Currículo trazable	Fuentes autorizadas, objetivos, prerrequisitos y ejemplos resueltos.
2	Estado del alumno	Historial estructurado, mastery y errores; opción de corregir el diagnóstico.
3	Política explícita	Cuándo pregunta, da pista, explica, practica, escala o retira ayuda.
4	Herramientas y verificación	Cálculo, código, citas, validación factual y manejo visible de incertidumbre.
5	Fricción productiva	Intento previo, pistas graduadas, no entregar respuestas y fading.
6	Control docente	Asignación, visibilidad, alertas, límites, override y escalamiento humano.
7	Privacidad mínima	Retención, uso para entrenamiento, acceso, borrado y protección de menores.
8	Auditoría	Logs exportables, versiones de modelo/prompts, incidentes y métricas por subgrupo.
9	Interoperabilidad	LMS, estándares, identidad, contenido y portabilidad del learner model.
10	Evidencia relevante	RCT o comparación creíble con examen sin ayuda, dosificación y costo total.

DISEÑO MÍNIMO DE UNA EVALUACIÓN SERIA

Dimensión	Estándar mínimo
Comparador	Control activo con igual tiempo, contenido y atención; distinguir “IA” de tiempo adicional o tutor humano.
Duración	Idealmente 8–16+ semanas, medición de uso real y seguimiento demorado.
Outcome primario	Prueba independiente sin asistencia; preregistrada; correctores ciegos cuando sea posible.
Mecanismos	Intentos, pistas, direct-answer rate, corrección de errores, self-explanation, persistencia y secuencia.
Heterogeneidad	Nivel inicial, género, lengua, SES, discapacidad, alfabetización digital y calidad docente.
Economía	Costo total por alumno y por 0.1 DE, incluyendo dispositivo, conectividad, capacitación, supervisión y soporte.
	Conclusión operativa. En 2026 la estrategia dominante debería ser “IA bajo protocolo pedagógico y liderazgo humano”. Es razonable escalar pilotos bien instrumentados; no es razonable comprar “personalización” sin acceso al learner model, sin evaluación autónoma y sin datos de uso.

FUENTES ESENCIALES

[1] Burneo, A., Dinarte-Díaz, L., Lopez, C. y Molina, E. (2026). Can EdTech Close Learning Gaps? Global Evidence from Digital Interventions. Banco Mund. [↗](#)

[2] Kestin, G. et al. (2025). AI tutoring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educat. [↗](#)

[3] Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakci, O. y Mariman, R. (2025). Generative AI without guardrails can harm learning: Evidence from hi. [↗](#)

[4] De Simone, M. E. et al. (2025). From Chalkboards to Chatbots: Evaluating the Impact of Generative AI on Learning Outcomes in Nigeria. World Bank Po. [↗](#)

[5] LearnLM Team, Google DeepMind y Fab AI (2026). Teaching with Gemini: Measuring the impact of Guided Learning on student mathematics progress in Sie. [↗](#)

[6] Wang, R. E., Ribeiro, A. T., Robinson, C. D., Loeb, S. y Demsky, D. (2024). Tutor CoPilot: A Human-AI Approach for Scaling Real-Time Expertise. [↗](#)

[7] LearnLM Team y Eedi (2025). AI tutoring can safely and effectively support students: An exploratory RCT in UK classrooms. [↗](#)

[8] Robinson, C. D., Gormley, D., Ribeiro, A. T. y Loeb, S. (2026). Access is Not Enough: Human Support Improves Engagement with AI Tutoring. [↗](#)

[10] Muralidharan, K., Singh, A. y Ganimian, A. J. (2019). Disrupting Education? Experimental Evidence on Technology-Aided Instruction in India. America. [↗](#)

[11] Roschelle, J., Feng, M., Murphy, R. F. y Mason, C. A. (2016). Online Mathematics Homework Increases Student Achievement. AERA Open. [↗](#)

[12] Nickow, A., Oreopoulos, P. y Quan, V. (2024). The Promise of Tutoring for PreK-12 Learning: A Systematic Review and Meta-Analysis of the Experiment. [↗](#)

[13] Khan Academy (2026). How Khan Academy Is Building a Better AI Tutor: Our Most Recent Learnings. [↗](#)

[14] OpenAI (2026). New tools for understanding AI and learning outcomes. [↗](#)